Обзор трёх статей по теме «Безопасность перевода Java-сервисов на виртуальные потоки ИИ-агентами: бенчмарк опасных мест и проверки во время работы»

Михаил Трифонов

FreshBrew: A Benchmark for Evaluating AI Agents on Java Code Migration

V. May, D. Misra, Y. Luo, A. Sridhar, J. Gehring, S. Soares Ribeiro Junior. ICSE 2026, с. 944–955. https://doi.org/10.1145/3744916.3773214

В FreshBrew ИИ-агенты переводят Java-проекты с Java 8 на JDK 17 и 21. Авторы отобрали из 30 000 популярных Maven-проектов 228, которые собираются и проходят тесты на Java 8, не собираются на Java 17 и покрыты тестами не меньше чем на 50 %. Миграция засчитывается, если проект компилируется, исходные тесты проходят без изменений и покрытие строк падает не больше чем на 5 процентных пунктов. Порог покрытия введён после того, как агенты начали обходить проверку. Один исключил падающие тесты в pom.xml, другой не заметил ошибку в журнале зелёного теста, третий заставил тест пропускать себя на новой версии Java. Gemini 2.5 Flash успешно перевела 52,3 % проектов на JDK 17 и 49,8 % на JDK 21, инструмент на правилах OpenRewrite 7 %. Бенчмарк охватывает только Maven и открытые проекты, каждую задачу авторы прогоняли один раз.

В FreshBrew, как и в моей работе, агент получает проект и должен его перевести. Но успех там определяют сборка, тесты и покрытие, а покрытие ловит удалённые тесты и не ловит ошибки, которые видны только под нагрузкой. Переход на виртуальные потоки даёт как раз такие ошибки.

Is Your Code Generated by ChatGPT Really Correct? Rigorous Evaluation of Large Language Models for Code Generation

J. Liu, C. S. Xia, Y. Wang, L. Zhang. NeurIPS 2023, с. 21558–21572.

Авторы дополнили тесты бенчмарка HumanEval автоматически. ChatGPT порождал входные данные для трудных случаев, мутация с учётом типов размножала их, а ответ модели сравнивался с эталонным решением. В HumanEval+ на каждую из 164 задач приходится в среднем 764 теста вместо 9,6, сокращённый набор в 47 раз меньше и почти так же строг. На 26 моделях доля решённых задач упала до 19,3–28,9 %, и рейтинг изменился. WizardCoder-CodeLlama и Phind-CodeLlama, проигрывавшие ChatGPT на старых тестах, на новых его обошли.

Слабые тесты завышают успех и меняют сравнение моделей. В миграции на виртуальные потоки тесты слабы по другой причине, ведь ни один функциональный тест не создаёт параллельной нагрузки, при которой проявляются закрепление потоков или снятый лимит. Сколько тестов ни добавь, эти ошибки останутся незамеченными, поэтому нужна проверка под нагрузкой.

Gray Failure: The Achilles' Heel of Cloud-Scale Systems

P. Huang, C. Guo, L. Zhou, J. R. Lorch, Y. Dang, M. Chintalapati, R. Yao. HotOS 2017. https://doi.org/10.1145/310298

По опыту эксплуатации Azure авторы пишут, что за большинством крупных сбоев облака стоит не остановка компонентов, а деградация вроде падения производительности, потери

пакетов или нестабильного ввода-вывода. Детекторы системы её не видят, а приложения от неё страдают, и такое расхождение авторы называют разной наблюдаемостью. В Azure избыточность коммутаторов повышала шанс, что запрос пройдёт через деградировавший, детектор не проходил путь, на котором была поломка, а перезагрузка перегруженного сервера хранения не устраняла причину и довела до каскадного отказа. Авторы предлагают строить детектор так, чтобы он видел систему глазами приложения.

После перевода на виртуальные потоки сервис может так же отвечать на проверку здоровья, пока соседний сервис перегружен из-за снятого лимита или запросы ждут занятых потоков-носителей. Поэтому моя проверка считает одновременные обращения к соседу и события закрепления потоков, а не коды ответов.

Мысли после чтения

Во всех трёх работах формальный признак успеха, будь то прохождение тестов или исправный по мнению детектора компонент, расходится с тем, что происходит на деле, и авторы ищут способ это расхождение сократить. Для миграций Java агентами его пока сокращают только требованием к покрытию тестами, и при смене модели конкурентности этого мало.

Я хочу измерить, как часто миграция агента, которую сборка и тесты признают успешной, опасна под нагрузкой, и проверить, становятся ли миграции безопаснее, если дать агенту проверку, которая смотрит на сервис под нагрузкой так, как его видят соседние сервисы.