На правах рукописи

Дочкина Виктория Сергеевна

Самоорганизация ИИ-систем на основе больших языковых моделей: протоколы координации и условия автономности

Специальность 1.2.2. Математическое моделирование, численные методы и комплексы программ

АВТОРЕФЕРАТ

диссертации на соискание ученой степени кандидата физико-математических наук

Долгопрудный
2026

Работа выполнена в федеральном государственном автономном образовательном учреждении высшего образования «Московский физико-технический институт (национальный исследовательский университет)».

Научный руководитель: **Буденный Семен Андреевич – кандидат физико-математических наук**

Ведущая организация: Автономная некоммерческая организация высшего образования «Университет Иннополис» (АНО ВО «Университет Иннополис»)

Защита состоится **«____» _____ 2026 года в ___ часов ___ минут** на заседании диссертационного совета **ФАКТ.1.2.2.____**, созданного на базе федерального государственного автономного образовательного учреждения высшего образования «Московский физико-технический институт (национальный исследовательский университет)» (МФТИ, Физтех) по адресу: 141701, Московская область, г. Долгопрудный, Институтский переулок, д. 9.

С диссертацией можно ознакомиться в библиотеке МФТИ, Физтех и на сайте организации https://mipt.ru.

Автореферат разослан «____» _____ 2026 г.

Ученый секретарь
диссертационного совета Быков Александр Андреевич

Общая характеристика работы

Актуальность темы. Развитие ИИ-агентов проходит три этапа. Сначала появляется *персональный* автономный агент, решающий задачи одного пользователя. Затем множество агентов объединяется в *автономную систему*, где отдельный агент становится одним из её инструментов. Наконец, автономные системы начинают взаимодействовать между собой в формате «агент–агент» — формируется *агентная экономика*, в которой ни один участник не подчинён другому, а согласие достигается без внешнего арбитра. На каждом переходе центральный вопрос смещается: уже не «как сделать агента умнее», а «как множеству автономных агентов действовать согласованно, если никто ими не управляет».

Доминирующий подход к построению многоагентных систем на основе больших языковых моделей (Large Language Models, LLM) — ChatDev, MetaGPT, AutoGen, CrewAI и др. — воспроизводит организационные паттерны человеческих коллективов: фиксированные должности, агент-менеджер, распределяющий задания, жёсткая иерархия [1—3]. Однако LLM-агент устроен иначе, чем сотрудник: он меняет специализацию за один вызов, читает контекст организации целиком, а в простое не потребляет ресурсов. Перенос человеческих ограничений на агентов, которые ими не обладают, ставит исследовательский вопрос работы: нужен ли автономной ИИ-организации координатор вообще — или достаточно, чтобы каждый агент знал *общую цель* и *фактическое состояние общего дела*, а всё остальное (роль, момент участия, право отказаться) решал сам?

Именно так устроены самоорганизующиеся системы в природе: в колонии общественных насекомых нет управляющего центра, каждый участник действует по следам, оставленным другими в общей среде (стигмергия), а согласованное поведение возникает как эмерджентный эффект [4; 5]. Спонтанное социальное поведение групп LLM-агентов уже наблюдалось [6; 7], однако принцип «координация без координатора» для многоагентных LLM-систем систематически не исследовался. Открытыми оставались три вопроса: при каком объёме автономии коллектив агентов работает лучше, чем под управлением; какая информация должна быть доступна агенту, чтобы самоорганизация не сводилась к дублированию усилий; какими свойствами должна обладать модель, чтобы автономия не обернулась падением качества.

Ответ имеет прямую практическую ценность: организация без координатора масштабируется добавлением агентов, не имеет единой точки отказа и платит только за полезную работу — три свойства, критичные и для автономных корпоративных систем, и для взаимодействия автономных агентов в формирующейся агентной экономике [8; 9]. Работа даёт эмпирически обоснованный ответ на все три вопроса на основе масштабного систематического вычислительного эксперимента по координации многоагентных LLM-систем: более 25 000 прогонов, 20 810 уникальных конфигураций, 9 LLM-моделей, группы (пулы агентов) от 4 до 256, 8 протоколов координации.

Степень разработанности проблемы. Теория многоагентных систем сформирована в работах по распределённому управлению, консенсусу и теории игр [10—13]; самоорганизация и роевой интеллект изучены в науке о сложности и биоинспирированных алгоритмах [4; 5]. С появлением LLM исследования разделились на два направления. *Вертикальное* самосовершенствование повышает способности отдельного агента: рефлексия без обновления весов [14], автономное наращивание навыков [15], метакогнитивная самомодификация [16], эволюционная оптимизация [17; 18]. *Горизонтальная* координация изучает взаимодействие групп агентов: фреймворки с фиксированными ролями [2; 3; 19], динамический набор команды при сохранении центрального рекрутера [20], обучаемая маршрутизация и оптимизация графов взаимодействия [21—23], проектирование системы по мета-обратной связи [24; 25]. Во всех этих подходах структура либо задаётся проектировщиком, либо обучается заранее; степень автономии агентов в координации как управляющий параметр не варьировалась, условия эффективности самоорганизации не установлены, эмерджентные эффекты при масштабировании до сотен агентов и воспроизводимость на открытых и закрытых моделях не изучены.

Объект исследования — самоорганизующиеся многоагентные системы на основе больших языковых моделей, действующие ради общей цели без выделенного агента-координатора. **Предмет исследования** — протоколы координации таких систем и условия (информационные, модельные, управленческие), при которых автономная самоорганизация превосходит внешнее управление.

Целью работы является выявление принципов и условий эффективной самоорганизации многоагентных систем на основе больших языковых моде-

лей: разработка и эмпирическая верификация спектра протоколов координации от экзогенного управления к эндогенной самоорганизации, установление информационных и модельных условий автономности и построение конституционной модели управления автономной ИИ-организацией.

Для достижения поставленной цели необходимо было решить следующие **задачи**:

1. Проанализировать существующие подходы к координации многоагентных LLM-систем и показать, что парадигма фиксированных ролей и централизованного управления переносит на ИИ-агентов ограничения, которыми они не обладают.
2. Формализовать автономную ИИ-организацию как стохастическую динамическую систему с дискретным временем и многокритериальным критерием качества и ввести шкалу эндогенности координации $E \in [0,1]$, классифицирующую протоколы по тому, какие организационные решения принимают сами агенты, а какие задаются извне.
3. Разработать спектр протоколов координации (Coordinator, Sequential, Broadcast, Shared и биоинспирированные), различающихся типом информации, доступной агенту, сформулировать гипотезу об эффекте эндогенности и информационное условие самоорганизации и теоретически обосновать преимущество фактического контекста перед предварительной координацией.
4. Реализовать программный комплекс для воспроизводимого вычислительного эксперимента (генерация банка задач четырёх уровней сложности, исполнение протоколов, независимая многокритериальная оценка качества, стоимости, времени, риска и соответствия миссии) и провести на нём эксперимент масштабом свыше 25 000 прогонов с контролем модели, числа агентов и сложности задач.
5. Эмпирически проверить эффект эндогенности и установить, какая информация — план координатора, намерения коллег, история прошлых задач или фактические результаты предшественников — обеспечивает наилучшую координацию; локализовать порог способностей модели, ниже которого самоорганизация уступает жёсткой структуре; описать эмерджентные свойства систем при масштабиро-

вании до 256 агентов и проверить воспроизводимость эффектов на закрытых и открытых моделях.

6. Разработать конституционную модель управления автономной ИИ-организацией, разграничивающую зоны человеческого контроля и автономии системы.

Методология и методы исследования. Методологическую основу работы составляет триада «модель — алгоритм — программа». Использованы аппарат стохастических динамических систем с дискретным временем и многокритериальной оптимизации; теория многоагентных систем и консенсуса; теория команд Маршака–Раднера и сравнение информационных структур по Блэкуэллу; спектральная теория графов (спектральный зазор Δ матрицы зависимостей агентов и спектр её лапласиана); теория самоорганизации и стигмергии; метод вычислительного эксперимента с контролируемым дизайном, при котором изучаемый фактор (протокол координации как целостная конфигурация) изолируется при фиксированных агентах, модели и банке задач; метод независимого судьи (LLM-as-a-judge) с многокритериальной декомпозицией оценки и отделением модели-судьи от моделей-агентов; методы математической статистики (двухвыборочный t-критерий, критерий Краскела–Уоллиса, размер эффекта Коэна d, поправка Бонферрони на множественные сравнения). Программная реализация выполнена в виде проблемно-ориентированных комплексов программ «MAS-as-a-Service» (исполнение протоколов, расчёт метрик, спектральный анализ) и «CSB-ITBIZ» (генерация и оценивание банка задач), зарегистрированных в Роспатенте.

Основные положения, выносимые на защиту:

1. **Эффект эндогенности.** На исследованном спектре протоколов зависимость качества многоагентной LLM-системы от степени автономии координации немонотонна: лучший результат даёт не централизованное управление и не полная свобода, а минимальный структурный каркас с максимальной ролевой автономией. Протокол Sequential, фиксирующий извне лишь очерёдность ходов и оставляющий агенту выбор роли и решение об участии, превосходит полностью автономный Shared на 44% (Cohen's $d = 1.86$, $p < 0.0001$) и централизованный Coordinator — на 14% ($p < 0.001$); преимущество по качеству воспроизведено на трёх моделях.

2. **Информационное условие самоорганизации.** Коллектив LLM-агентов выше порога способностей координируется без выделенного координатора, когда информационное множество каждого агента в момент его хода содержит общую цель и *фактические результаты* предшественников в текущей задаче. Для команды с общей целью доказана теорема о вложении протоколов: оптимальная команда в Sequential достигает качества не ниже, чем в Coordinator, Broadcast и Shared, при не большем числе LLM-вызовов, а разрыв может быть строгим и равен ценности информации, возникающей только при исполнении (цена плана). По качеству координации типы информации упорядочены как факт $>$ план координатора $>$ намерения коллег $\approx$ история прошлых задач; порядок воспроизведён на трёх моделях (Claude Sonnet 4.6, DeepSeek v3.2, GLM-5; $p < 0.001$ в каждом случае).
3. **Условие автономности и порог способностей.** Самоорганизация эффективна только при одновременном выполнении двух условий — достаточно способной модели и подходящего протокола; их вклады не складываются (смена протокола даёт до 44% разницы в качестве, смена модели — около 14%, а знак эффекта автономии зависит от модели). На исследованных моделях локализован порог способностей, ниже которого наблюдается *эффект реверсии*: жёсткая структура превосходит автономию (у Claude Sonnet 4.6 свобода даёт от $+3.5$% до $+10.6$% качества в зависимости от выбора baseline фиксированных ролей, у GLM-5 — -9.6%). Порог определяется саморефлексией (частота добровольного самоотвода 8.6% против 0.8%), многошаговым рассуждением и следованием инструкциям.
4. **Эмерджентные свойства и воспроизводимость.** При росте группы снижения качества не обнаружено: с 8 до 64 агентов при фиксированных ролях Q остаётся в пределах 0.949–0.955 при росте стоимости лишь на 11.8%; при росте пула агентов с 64 до 256 с динамическим отбором участников значимых различий нет ($p = 0.61$). Без внешнего проектирования система порождает специализацию (при свободном выборе роли индекс стабильности ролей RSI $\to 0$; при $N = 16$ агенты Claude Sonnet 4.6 использовали 1 272 различных роли с рав-

номерной нагрузкой, Gini $= 0.055$), реализует добровольный самоотвод (избирательный, а не массовый: в задаче участвуют 87–95% агентов), выстраивает плоские иерархии глубиной не более двух уровней и восстанавливает качество после удаления агентов или подмены модели. Эффекты воспроизводятся на закрытых и открытых моделях: DeepSeek v3.2 достигает 95% качества Claude Sonnet 4.6 при стоимости API в 24 раза ниже.

Научная новизна:

1. Впервые степень автономии координации в многоагентных LLM-системах введена как управляющий параметр (шкала эндогенности E) и систематически варьировалась в вычислительном эксперименте; обнаружен и статистически подтверждён *эффект эндогенности* — немонотонная зависимость качества от автономии с максимумом внутри исследованного спектра протоколов.
2. Сформулировано, теоретически обосновано и эмпирически подтверждено *информационное условие самоорганизации*: координация без координатора при доступе каждого агента к общей цели и фактическому состоянию задачи; доказана теорема о вложении протоколов, по которой оптимальная команда в Sequential не уступает протоколам с предварительной координацией (Coordinator, Broadcast, Shared) при не большем числе вызовов; установлен порядок типов информации по качеству координации (факт $>$ план $>$ намерения $\approx$ история).
3. Введён и эмпирически локализован *порог способностей* модели, разделяющий режимы, в которых самоорганизация полезна либо вредна; выявлен эффект реверсии, показано взаимодействие (неаддитивность) вкладов протокола и модели и дано теоретическое истолкование реверсии как признака недооптимальности политики модели, невозможного для оптимальной команды.
4. Впервые на пулах до 256 агентов описан комплекс эмерджентных свойств самоорганизующихся LLM-систем: RSI $\to 0$ при свободном выборе роли, добровольный самоотвод, плоская иерархия, независимость стоимости задачи от размера пула, стабильность спектрального зазора матрицы зависимостей, восстановление качества после удаления агентов и подмены модели.

5. Предложена концепция «роль как функция момента, а не должность» и обоснован отказ от предварительного назначения ролей как антипаттерна, переносящего ограничения человека на ИИ-агентов; показана экономика самоотвода, при которой стоимость системы пропорциональна полезной работе, а не численности.
6. Разработана конституционная (трёхкольцевая) модель управления автономной ИИ-организацией, связывающая границы автономии с многокритериальными метриками качества и устойчивости.

Теоретическая и практическая значимость. Теоретическая значимость состоит в развитии формального аппарата описания самоорганизации многоагентных LLM-систем: введены шкала эндогенности и информационное условие самоорганизации; доказана теорема о вложении протоколов, придающая этому условию точную форму и связывающая эффект реверсии с недооптимальностью политики модели; введены многокритериальная модель оценки (качество, риск, время, стоимость, соответствие миссии), индексы стабильности ролей и устойчивости, условия автономности; естественноязыковая координация сопоставлена с классической задачей консенсуса в пространстве эмбеддингов, что даёт спектральные характеристики (спектральный зазор, глубина иерархии) для описания самоорганизовавшихся структур. Практическая значимость определяется конструктивным рецептом построения автономной ИИ-организации: вместо назначения ролей и написания инструкций достаточно задать миссию, выбрать протокол координации и обеспечить модель выше порога способностей. Рекомендации (протокол Sequential, инвестиции в качество модели вместо числа агентов, мультимодельные конфигурации с открытыми моделями, конституционные границы автономии) применимы к корпоративной автоматизации и комплаенс-анализу, а принцип «координация без координатора» задаёт основу для взаимодействия автономных агентов в формате «агент–агент» — там, где ни один участник не может быть назначен управляющим [9; 11]. Разработанные принципы и программные комплексы апробированы в индустриальных условиях (ПАО Сбербанк); отдельные выводы использованы при формировании стратегии перспективных технологических направлений.

Достоверность результатов. Достоверность результатов обеспечивается масштабом эксперимента (более 25 000 прогонов, 20 810 уникальных конфи-

гураций), контролируемым дизайном с изоляцией изучаемого фактора (одни и те же агенты, модель и банк задач одного уровня сложности при смене только протокола), независимой многокритериальной оценкой качества (модель-судья фиксирована внутри серии и едина для всех сравниваемых конфигураций: GPT-4o в сериях 1–2, GPT-5.4 в серии 3; в межмодельных сравнениях судья не входит в число сравниваемых моделей; температура судьи 0.0) и статистической проверкой гипотез (двухвыборочный t-критерий, критерий Краскела–Уоллиса, размер эффекта по Коэну). Ключевые выводы ($p < 0.0001$ для сравнения Sequential–Shared; $p < 0.001$ для Sequential–Coordinator на трёх моделях) остаются значимыми при поправке Бонферрони ($\alpha = 0.0025$). Результаты воспроизведены на закрытых (Claude Sonnet 4.6, GPT-4.1-mini) и открытых (DeepSeek v3.2, GLM-5) моделях и проверены на нижней границе (GigaChat 2 Max). Все промпты, конфигурации и логи прогонов сохранены; банк задач сформирован зарегистрированной программой и воспроизводим.

Соответствие паспорту специальности. Работа выполнена в рамках специальности 1.2.2 (физико-математические науки) и соответствует пунктам её паспорта: п. 1 (разработка новых математических методов моделирования) — построена модель самоорганизующейся ИИ-системы как стохастической динамической системы с управляющим параметром эндогенности; п. 2 (разработка, обоснование и тестирование эффективных вычислительных методов) — протоколы координации разработаны и протестированы как вычислительные алгоритмы средствами спектрального анализа и вычислительного эксперимента; п. 3 (реализация численных методов и алгоритмов в виде комплексов проблемно-ориентированных программ) — комплексы «MAS-as-a-Service» и «CSB-ITBIZ»; п. 8 (комплексные исследования научных проблем с применением математического моделирования и вычислительного эксперимента) — проверка адекватности модели и статистических гипотез на масштабе свыше 25 000 прогонов.

Апробация работы. Результаты работы доложены на 68-й Всероссийской научной конференции МФТИ в честь 130-летия со дня рождения Н. Н. Семёнова (Долгопрудный, 30 марта — 4 апреля 2026 г.) в трёх докладах: «Эмерджентная самоорганизация и устойчивость автономных многоагентных LLM-систем к внешним шокам», «Вычислительный эксперимент по исследованию спектральных характеристик координации в многоагентных системах на базе

больших языковых моделей» и «Масштабирование и эмерджентные эффекты в многоагентных системах на базе больших языковых моделей»; тезисы докладов опубликованы в сборниках конференции (тома «Прикладная математика и информатика» и «Аэрокосмические технологии»). Программные комплексы «MAS-as-a-Service», «Ника» и «CSB-ITBIZ» зарегистрированы в Реестре программ для ЭВМ Роспатента (свидетельства № 2026685681, № 2026687329 и № 2026687342). Протоколы координации, методика многокритериальной оценки и зарегистрированные комплексы программ внедрены в ПАО Сбербанк при разработке и пилотировании автономных ИИ-систем.

Личный вклад. Все основные результаты, выносимые на защиту, получены автором лично. Автору принадлежат постановка исследовательского вопроса, формализация модели и шкалы эндогенности, разработка протоколов координации и методики многокритериальной оценки, дизайн вычислительного эксперимента, реализация программных комплексов (зарегистрированных в Роспатенте), проведение всех серий прогонов, статистический анализ данных и формулировка теоретических выводов, включая эффект эндогенности, информационное условие самоорганизации, условия автономности и конституционную модель управления.

Публикации. Опубликованы три статьи в рецензируемых научных журналах: две — в изданиях из перечня ВАК («Труды МФТИ», 2026, т. 18, № 3, с. 87–93; «Искусственный интеллект и принятие решений», 2026, № 3, с. 91–106) и одна, в соавторстве, — в индексируемом Scopus издании IEEE Access (Q1; 2026, т. 14, с. 58262–58281). Ещё одна статья в соавторстве принята в печать в IEEE Access, а статья с полным описанием вычислительного эксперимента подана в IEEE Access (препринт arXiv:2603.28990). Опубликованы тезисы трёх докладов 68-й Всероссийской научной конференции МФТИ. Получены три свидетельства о государственной регистрации программ для ЭВМ. Полный список из 11 позиций приведён в разделе «Публикации автора по теме диссертации»; по его нумерации положения 1 и 3 опубликованы в работах [2, 6, 11], положение 2 — в работах [2, 11] (теорема о вложении протоколов публикуется впервые), положение 4 — в работах [1, 4, 5, 11]; программная реализация зарегистрирована как [7–9]; работы [3, 10] посвящены памяти LLM-агентов (хранению и извлечению знаний; гл. 2–3). В работах с соавторами [3, 10] автору

принадлежат идея и концепция исследования, разработка части программного кода, внедрение и масштабирование результатов в ПАО Сбербанк.

Объём и структура работы. Диссертация состоит из введения, пяти глав, заключения, списка сокращений и условных обозначений, словаря терминов, списка литературы и списка публикаций автора по теме диссертации. Полный объём диссертации составляет 126 страниц с 11 рисунками и 13 таблицами. Список литературы содержит 67 наименований.

Содержание работы

Во **введении** обоснована актуальность темы, сформулированы цель и задачи работы, положения, выносимые на защиту, научная новизна, теоретическая и практическая значимость, приведены сведения о методологии, достоверности, апробации и публикациях.

Первая глава рассматривает большие языковые модели как вычислительную основу самоорганизующихся ИИ-систем. Фундаментальная модель определяется как параметрическая функция $f_\theta \colon \mathcal{X} \to \mathcal{Y}$, а её адаптация — композицией $\hat{f}_{\theta,\psi} = g_\psi(f_\theta)$, где g_ψ — оператор дообучения, настройки на инструкции или обучения предпочтениям. Выделены три свойства, от которых далее зависит способность модели к самоорганизации: многошаговое рассуждение, точное следование инструкциям и способность оценивать собственную компетентность. Показано, что эмерджентность способностей при преодолении критического масштаба N_{critical} является прототипом введённого в главе 4 *порога способностей*: свойство, отсутствующее у слабой модели, появляется скачком, а не постепенно. Ограничения LLM (стоимость вывода, галлюцинации, prompt-инъекции) далее учитываются как метрики стоимости C и риска R.

Вторая глава посвящена многоагентным системам на основе LLM (FM-MAS) и механизмам их координации. FM-MAS определяется как кортеж $\mathcal{S} = (\mathcal{A}, \mathcal{F}, \mathcal{C}, \mathcal{E})$ — агенты, фундаментальные модели, система координации и среда с инструментами; граф взаимодействия $G = (\mathcal{A}, \mathcal{E}_G)$ задаёт разрешённые каналы связи. Систематический обзор фреймворков показывает, что все они реализуют *экзогенную* координацию: ChatDev и MetaGPT закрепляют должности и процедуры, AutoGen строит диалог вокруг заданного сценария, AgentVerse динамически набирает команду, но сохраняет центрального рекрутера, GPTSwarm и ReSo оптимизируют структуру заранее по данным,

AgentNet маршрутизирует без оркестратора, но по накопленной истории взаимодействий, Chain-of-Agents передаёт результаты по цепочке при фиксированных ролях и порядке. Отдельно рассмотрены работы со спонтанным социальным поведением групп агентов (Generative Agents, CAMEL) и линия *вертикального* самосовершенствования отдельного агента (Reflexion, Voyager, гиперагенты), ортогональная изучаемой в работе *горизонтальной* координации. Для естественноязыковой координации построен формальный мост к классической теории консенсуса: если предложения агентов отображены в эмбеддинги $z_{i,t} = \phi(\text{proposal}_{i,t})$ и итеративно усредняются, $z_{t+1} = W z_t$, то при связном G и стохастической примитивной W представления сходятся к общему пределу z^*; эта идеализированная линейная схема служит источником спектральных характеристик (λ_2) и языком интерпретации, а не гарантией сходимости для LLM-агентов. Сформулирован пробел: степень автономии агентов как управляющий параметр систематически не варьировалась в известных работах.

Третья глава содержит формальную модель автономной ИИ-организации и спектр протоколов координации. Организация из N агентов моделируется как стохастическая динамическая система с дискретным временем

$$x_{t+1} = F(x_t, u_t, \tau_t, w_t, \varepsilon_t),$$

где x_t — состояние (роли, топология, организационная память), u_t — решения координации, τ_t — задача, w_t — внешние возмущения, ε_t — стохастичность генерации. На каждом шаге измеряются качество Q_t, соответствие миссии M_t, время T_t, стоимость C_t и риск R_t; оптимизируется накопленный критерий

$$J = \mathbb{E}\Big[\sum_{t=1}^{T}\big(\alpha_Q Q_t + \alpha_M M_t - \alpha_T T_t - \alpha_C C_t - \alpha_R R_t\big)\Big], \qquad \alpha_i > 0,$$

при ограничениях на допустимые риск и стоимость. Ключевая управляющая переменная — *степень эндогенности* $E \in [0,1]$. Она определяется операционально: по пяти классам организационных решений — выбор роли, участие, очерёдность, декомпозиция задачи, состав видимой информации — фиксируется, какие принимает каждый агент сам, какие агент-координатор, а какие заданы протоколом; чем больше классов отдано агентам, тем выше E. Численные значения E — условные координаты, упорядочивающие протоколы; выводы

работы опираются на этот порядок и состав эндогенных решений, а не на сами числа. Каждому протоколу отвечает свой набор эндогенных решений и тип доступной агенту информации (табл. 1, рис. 1); помимо четырёх основных протоколов исследованы четыре биоинспирированных (морфогенетический, клональный, стигмергический, «рябь») с передачей контекста через следы в среде.

Таблица 1 — Спектр протоколов координации

Протокол	E	**Эндогенно: роль / участие / порядок**	**Что видит агент**	**LLM-вызовов**
Coordinator	0.2	K / K / K	План агента-координатора	$N + 1$
Sequential	0.5	+ / + / —	Готовые результаты предшественников в текущей задаче	N (последовательно)
Broadcast	0.7	+ / + / +	Намерения коллег (два раунда)	$2N$
Shared	0.8	+ / + / +	Историю ролей в прошлых задачах	N (параллельно)

«+» — решает каждый агент сам; «—» — задано протоколом; «K» — решает агент-координатор за остальных

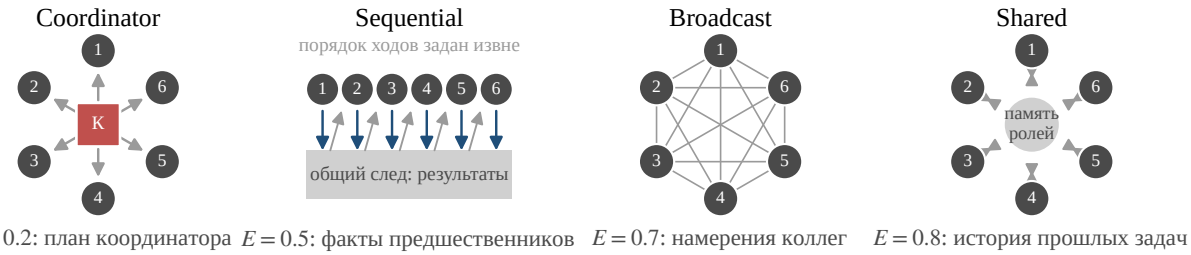


Рис. 1 — Спектр протоколов координации: от централизованного плана (Coordinator) к самоорганизации через следы в общей среде (Sequential) и полностью автономным режимам (Broadcast, Shared); E — степень эндогенности

Протокол Sequential задан как алгоритм. Агенты $a_1, \ldots, a_N$ упорядочены извне; для $i = 1, \ldots, N$: (1) агент получает информационное множество $\mathcal{I}_i = \{\text{миссия}, \tau_t, \{y_j\}_{j \prec i}\}$, где y_j — готовые вклады предшественников; (2) на его основе сам выбирает роль r_i либо воздерживается ($r_i = \varnothing$); (3) участвующий агент формирует вклад y_i и оставляет его в общем контексте задачи. Ни один агент не имеет привилегированной позиции, прямого обмена сообщениями нет, число LLM-вызовов равно N; по существу это стигмергическая координация.

Сравнение протоколов по типу информации даёт *информационное условие самоорганизации*: коллектив координируется без координатора, когда для каждого агента $\{\text{миссия}, \tau_t, \{y_j\}_{j \prec i}\} \subseteq \mathcal{I}_i$. В Sequential условие выполнено для всех агентов; Coordinator подменяет факт планом, составленным до начала работы, Broadcast — намерениями, которые могут не реализоваться, Shared — историей, не связанной с текущей задачей. Отсюда центральная гипотеза работы — *эффект эндогенности*: качество немонотонно вдоль спектра протоколов и максимально на Sequential, поскольку Coordinator создаёт единую точку отказа, а Broadcast и Shared приводят к дублированию ролей из-за отсутствия видимости текущих решений; протоколы сравниваются как целостные конфигурации, и разделение вкладов их отдельных признаков требует факторного эксперимента. Введены *индекс стабильности ролей* RSI (предел RSI $\to 0$ означает, что агент выбирает специализацию заново для каждой задачи) и механизм *добровольного самоотвода*; обоснован тезис «роль как функция момента, а не должность»: для LLM-агента переключение специализации имеет нулевую стоимость, поэтому предварительное назначение ролей — антипаттерн. Отдельный раздел главы даёт расчётные определения метрик (RSI, доля самоотвода, спектральный зазор Δ и глубина иерархии по матрице зависимостей, индекс устойчивости $\text{RI} = Q/Q^{\text{pre}}$).

Информационному условию придана точная форма. Рассматривается решение одной задачи τ командой из N агентов с общей целью; ход исполнения зависит от скрытого состояния среды ω, проявляющегося только при выполнении работы, так что результат хода агента $y_i = g(a_i, \tau, \omega, \eta_i)$ несёт информацию об ω, которой до хода не было ни у кого. Ценность протокола $V^*(\Pi)$ — супремум ожидаемого качества по всем допустимым в протоколе профилям стохастических стратегий (задача теории команд Маршака–Раднера). Coordinator, Broadcast и Shared — протоколы с *предварительной координацией*: всё, что агент получает сверх миссии, задачи и организационной памяти, порождено до начала исполнения и не зависит от ω. **Теорема (о вложении протоколов).** Если до начала исполнения ни у кого нет приватной информации, служебная часть вклада может нести произвольное сообщение, а качество оценивается по содержательным вкладам, то $V^*(\text{Seq}) \geq V^*(\Pi')$ для любого протокола с предварительной координацией Π', причём при не большем числе LLM-вызовов (N против $N+1$ у Coordinator и $2N$ у Broadcast). Доказательство — явная эмуляция:

первый агент очереди порождает план или намерения с тем же распределением, что координатор, и оставляет их в общем контексте, остальные действуют как исполнители; экзогенный порядок ходов — единственный элемент структуры, который для этого нужен. **Следствие (цена плана).** Неравенство строгое, когда исполнение раскрывает значимую для последователей информацию об ω: в примере с K равновероятными состояниями среды $V^*(\mathrm{Seq}) = 1$, а у остальных протоколов $V^* = 1/K$. Теорема относится к оптимальной команде и опирается на общность цели (для игр с несовпадающими интересами ценность информации может быть отрицательной); для реальной модели с ограниченным классом политик неравенство может нарушаться, поэтому знак разности качества Sequential и Coordinator (равно как свободных и фиксированных ролей) служит операциональным критерием порога способностей, а эффект реверсии — диагностикой недооптимальности политики модели, а не преимуществом жёсткой структуры.

Четвёртая глава формулирует условия автономности и конституционную модель управления. Самоорганизация требует одновременно способной модели и подходящего протокола, причём их вклады не складываются: смена протокола на одной модели меняет качество до 44%, смена модели при одном протоколе — около 14%, а знак эффекта автономии зависит от модели; сильная модель под централизованным протоколом теряет 9–11 п.п. качества, а самоорганизация на слабой модели уступает жёсткому расписанию ролей. Выделены три способности, определяющие *порог способностей*: саморефлексия (умение оценить собственную компетентность и воздержаться), многошаговое рассуждение и следование инструкциям. Ниже порога наблюдается *эффект реверсии*: фиксированные роли превосходят свободную самоорганизацию. Описана *экономика самоотвода*: воздержавшийся агент оплачивает лишь короткий вызов с решением об отказе, поэтому стоимость почти пропорциональна полезной работе, а не численности. Предложена трёхкольцевая конституция автономной ИИ-организации (табл. 2) с принципом: чем ближе решение к стратегическому «зачем», тем больше человеческого контроля; чем ближе к операционному «как», тем больше автономии.

Условия автономности применены к автономизации корпоративных процессов. Введена модель автономного бизнес-процесса $\mathrm{ABPS} = (A, W, R, M, \Omega)$ с графом рабочего процесса W, бизнес-правилами R и инвари-

Таблица 2 — Трёхкольцевая конституция автономной ИИ-организации

Кольцо	**Содержание**	**Кто обновляет**
Ядро	Миссия, ценности, принцип самоорганизации, право на самоотвод	Только человек
Стандарты	Требования к агентам, метрики здоровья системы, аудит	Человек и система
Протоколы и инструменты	Координационные параметры, пороги самоотвода, размеры батчей, tools/skills	Система (A/B-тесты)

антами Ω, описаны контур plan–validate–execute–monitor и интерпретируемое правило эскалации $\text{HumanReview} = \mathbb{I}[\text{RiskScore} > \tau] \vee \mathbb{I}[\text{Compliance} = 0]$.

Пятая глава содержит экспериментальное исследование. Проверялись пять гипотез: H1 — эффект эндогенности (Sequential превосходит и Coordinator, и Shared); H2 — условие автономности (нужны одновременно сильная модель и подходящий протокол, ниже порога — реверсия); H3 — масштабирование (при росте группы с фиксированными ролями до 64 агентов и пула с динамическим отбором участников до 256 качество не падает, стоимость задачи растёт медленнее, чем линейно по N); H4 — эмерджентность (динамическое изобретение ролей, добровольный самоотвод, плоские иерархии без внешнего проектирования); H5 — воспроизводимость на закрытых и открытых моделях. Проведён систематический вычислительный эксперимент: более 25 000 прогонов, 20 810 уникальных конфигураций, 9 моделей, пулы от 4 до 256 агентов, 8 протоколов, 4 уровня сложности задач — от однодоменных L1 (3–5 шагов) до состязательных L4 (3+ домена, конфликт интересов стейкхолдеров, неполная информация). Эксперимент организован в три серии (табл. 3) и выполнен в авторском программном комплексе «MAS-as-a-Service»; банк задач на русском и английском языках сформирован программой «CSB-ITBIZ».

Качество оценивается моделью-судьёй, единой для всех конфигураций внутри серии (GPT-4o в сериях 1–2, GPT-5.4 в серии 3), по четырём субкритериям — точность, полнота, связность, применимость — по 4-балльной шкале: $Q_t = (s_{acc} + s_{comp} + s_{coh} + s_{act})/16 \in [0.25, 1]$; отдельно оценивается соответствие миссии s_{mis}. Интегральный индекс баланса $B_t = w_Q \hat{Q}_t + w_M \hat{M}_t + w_T \hat{T}_t + w_C \hat{C}_t +$

Таблица 3 — Дизайн эксперимента

Серия	**Фокус**	**Модели**	**Агентов**	**Конфигураций**
1	Фундамент	GPT-4o	4	660
2	Масштабирование	GPT-4o-mini (судья GPT-4o)	4–64	8 020
3	Мультимодельность, протоколы	Claude Sonnet 4.6, GPT-5.4, GPT-4o, GPT-4.1-mini, DeepSeek v3.2, GLM-5, Gemini-3-flash, GigaChat 2 Max	8–256	12 130

$w_R \hat{R}_t$ с весами $0.25, 0.20, 0.20, 0.20, 0.15$. Температура агентов 0.7, судьи — 0.0; абсолютные Q сравнимы только внутри серии.

Эффект эндогенности (H1). Прямое сравнение четырёх протоколов при одинаковых агентах, модели и банке задач одного уровня сложности (табл. 4, рис. 2) показало сильную зависимость качества от механизма координации: разница между Sequential и Shared составляет 44% (Cohen's $d = 1.86$, $p < 0.0001$), между Sequential и Coordinator — 14% ($p < 0.001$); у Claude Sonnet 4.6 общая стоимость задачи при Sequential на 24% ниже, чем при Coordinator (37.1 против 48.9 тыс. токенов), у открытых моделей соотношение стоимостей обратное при сохранении выигрыша по качеству. Преимущество Sequential над Coordinator на задачах L3 ($N = 16$, 120 задач на модель) воспроизведено на трёх моделях: Claude Sonnet 4.6 (0.875 против 0.767, $+14.1\%$), DeepSeek v3.2 (0.829 против 0.738, $+12.4\%$), GLM-5 (0.800 против 0.713, $+12.2\%$); во всех случаях $p < 0.001$. Порядок протоколов по качеству совпадает с порядком по типу доступной агенту информации: факт (Sequential) $>$ план (Coordinator) $>$ намерения (Broadcast) $\approx$ история (Shared) — эмпирическое содержание информационного условия.

Таблица 4 — Сравнение протоколов (пилот: $N = 8$, Claude Sonnet 4.6, L3+L4, 60 задач на протокол; финал Q_{L3}: $N = 16$, Claude Sonnet 4.6, 30 задач на протокол; $1 - R$ — дополнение метрики риска)

Протокол	$Q_{\text{пилот}}$	Q_{L3}	**Balance**	**1 − R**
Coordinator	0.640	0.767	0.478	0.774
Sequential	**0.724**	**0.875**	**0.510**	**0.829**
Broadcast	0.510	—	0.363	0.580
Shared	0.503	—	0.369	0.589

Масштабирование (H3). При фиксированных ролях (серия 2, GPT-4o-mini) восьмикратный рост группы с 8 до 64 агентов не изменил качества (Q в

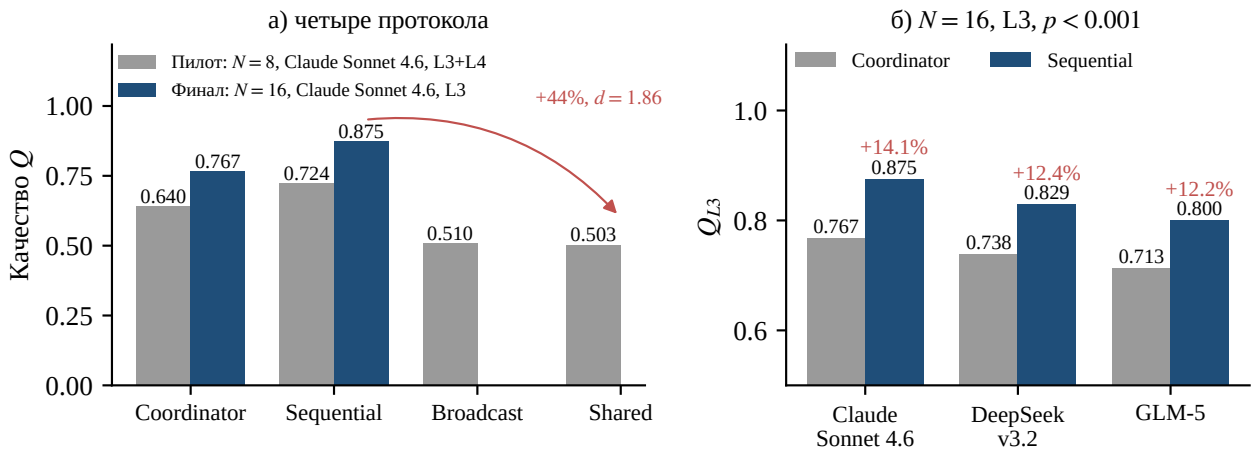


Рис. 2 — Эффект эндогенности: а) качество четырёх протоколов в пилотной и финальной постановках; б) воспроизведение преимущества Sequential над Coordinator на трёх моделях

диапазоне 0.949–0.955), а стоимость выросла лишь на 11.8% (с 3 164 до 3 537 токенов; рис. 3). При динамическом отборе рабочей группы из пула (серия 3: рабочую группу на каждой задаче протокол формирует из пула по топологии взаимодействия или профилям навыков) увеличение пула с 64 до 256 агентов также не привело к значимому изменению качества (критерий Краскела–Уоллиса $H = 1.84$, $p = 0.61$; $Q \in [0.958, 0.967]$; по 1 500 задач на каждое N; тест на эквивалентность не проводился, поэтому результат означает «снижение не обнаружено»), а стоимость задачи от размера пула не зависит (3.7–3.8 тыс. токенов): она определяется составом рабочей группы, а не численностью пула.

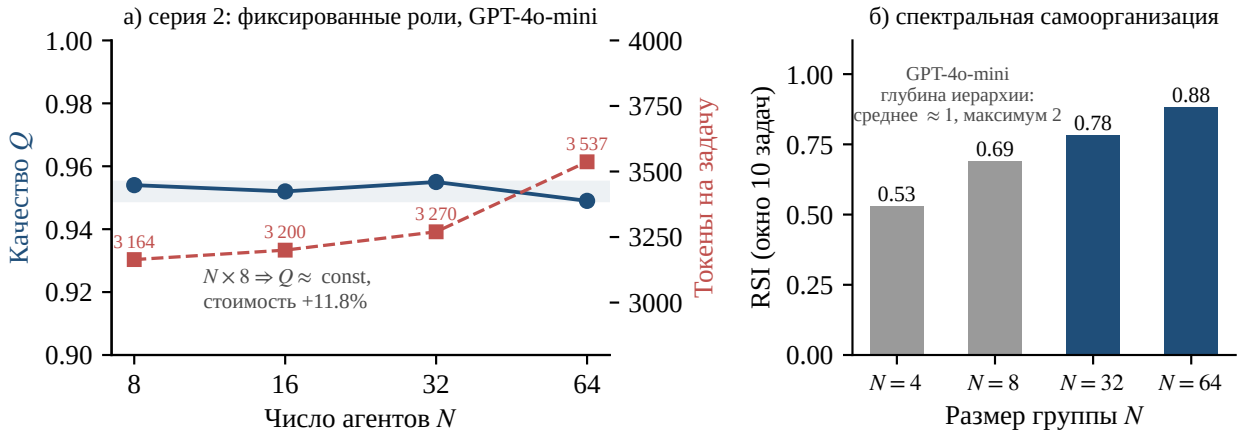


Рис. 3 — Масштабирование: а) качество и стоимость при росте группы с 8 до 64 агентов (серия 2, фиксированные роли); б) индекс стабильности ролей при спектральной самоорганизации, $N = 4$–64 (серия 2, GPT-4o-mini)

Условия автономности (H2). При одинаковой топологической координации ($N = 32$, 300 задач на модель) разрыв между сильнейшей и слабейшей моделью достигает 174% (Q от 0.978 у DeepSeek v3.2 до 0.357 у Gemini-3-flash); при этом место модели зависит от постановки — Claude Sonnet 4.6 набирает лишь 0.689 в заданной топологии, но 0.875 под Sequential-самоорганизацией. Прямое сравнение свободной самоорганизации с фиксированными ролями ($N = 8$, L3+L4) выявило эффект реверсии: у Claude Sonnet 4.6 свобода повышает качество (0.594 против 0.537 при фиксированных ролях той же модели, $+10.6\%$; относительно лучшего фиксированного baseline 0.574 — $+3.5\%$), у GLM-5 — снижает (0.519 против 0.574, -9.6%). Различие связано с саморефлексией: Claude добровольно воздерживается в 8.6% случаев, GLM-5 — в 0.8% (рис. 4, а).

Закрытые и открытые модели (H5). На задачах L3 ($N = 16$, Sequential) DeepSeek v3.2 уступает Claude Sonnet 4.6 на 5.5% ($p < 0.001$), то есть достигает 95% её качества при стоимости API примерно в 24 раза ниже (табл. 5); на состязательных задачах L4 преимущество переходит к DeepSeek ($+6.0\%$, $p = 0.082$). Соответствие миссии у обеих моделей максимально ($4.00/4.00$). Нижняя граница способности к самоорганизации определена на GigaChat 2 Max: $Q = 0.569$, или 77.5% от уровня Claude ($p < 0.0001$), при самоотводе 24% против 9%, что оборачивается меньшим ролевым покрытием задачи. Итоговый ряд: Claude $>$ DeepSeek $\approx$ GLM-5 $\gg$ GigaChat (рис. 4, б).

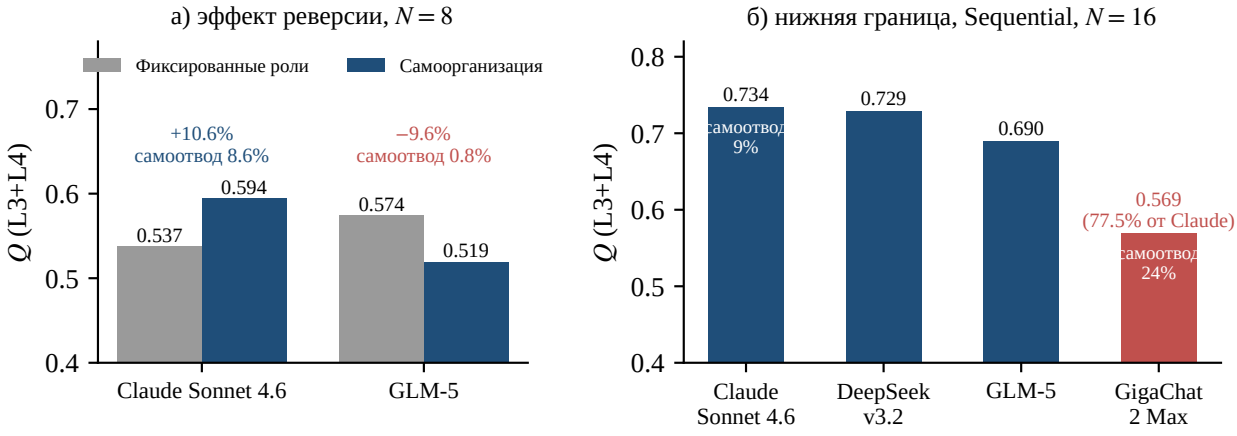


Рис. 4 — Порог способностей: а) эффект реверсии — свобода самоорганизации помогает Claude Sonnet 4.6 и вредит GLM-5; б) нижняя граница способности к самоорганизации (GigaChat 2 Max)

Таблица 5 — Закрытые и открытые модели ($N = 16$, Sequential, судья GPT-5.4)

Модель	Q_{L3}	Q_{L4}	**Токены (L3)**	$Q/1K$
Claude Sonnet 4.6	0.875	0.594	37K	0.0236
DeepSeek v3.2	0.829	0.629	47K	0.0177
GLM-5	0.800	0.579	57K	0.0140

Эмерджентные свойства (H4). При свободном выборе роли индекс стабильности ролей во всех конфигурациях стремится к нулю: ни один агент не удерживает роль на протяжении десяти задач подряд; при $N = 16$ на 120 задачах агенты Claude Sonnet 4.6 использовали 1 272 различных названия ролей при почти равномерной нагрузке (Gini $= 0.055$), агенты DeepSeek v3.2 — 989 (Gini $= 0.176$) — агенты не оседают в постоянных позициях, а заново подбирают специализацию под задачу. Под Sequential в показательном прогоне 38 из 60 незанятых агентов вышли из задачи по собственному решению, тогда как под Coordinator все 60 были отсеяны командой; в целом в решении участвовали 87–95% агентов ($N = 16$), то есть самоотвод избирателен. Иерархия остаётся плоской (средняя глубина около 1, максимум 2 при $N = 64$) и углубляется лишь с ростом сложности задачи (с 1.22 на L1 до 1.56 на L4), тогда как качество падает с 0.99 на L1–L2 до 0.61 на L4: состязательные задачи остаются наиболее трудным классом. В серии со спектральной самоорганизацией, где агенты имеют постепенно меняющиеся профили навыков, специализация с ростом группы усиливается (доля агентов, удерживающих роль в окне из десяти задач, — с 0.53 при $N = 4$ до 0.88 при $N = 64$), а спектральный зазор матрицы зависимостей сохраняется при любом N ($\Delta \approx 1.93$).

Устойчивость к шокам. При трёх типах возмущений на $N = 32$ (серия 2, GPT-4o-mini) — случайное удаление агента, удаление узлового агента, подмена модели у четверти участников, причём внутри окна возмущения к оценке судьи применялся заданный штраф (-0.07 при удалении агента, -0.03 за подменённого участника) — качество восстанавливалось без внешнего вмешательства: индекс устойчивости RI $= Q/Q^{\text{pre}}$ составил в среднем 0.94 для координации по разреженному графу и 0.98 для спектральной самоорганизации, время восстановления — от 1.3–2.3 задач (удаление агента, полный граф) до 6–9 задач (степенная сеть, спектральная самоорганизация).

Итоги сведены в табл. 6: данные согласуются со всеми пятью гипотезами.

Таблица 6 — Итоги проверки гипотез

Гипотеза	**Ключевой результат**	**Статистика**
H1. Эффект эндогенности	Sequential превосходит Shared на 44% и Coordinator на 14%; преимущество воспроизведено на трёх моделях	$d = 1.86$, $p < 0.0001$; $p < 0.001$
H2. Условие автономности	Вклады протокола (до 44%) и модели (≈14%) не складываются; реверсия: от $+3.5\%$ до $+10.6\%$ у Claude против -9.6% у GLM-5	самоотвод 8.6% против 0.8%
H3. Масштабирование	Снижения качества не обнаружено при $N = 8 \to 64$ (фиксированные роли, стоимость $+11.8\%$) и при росте пула $N = 64 \to 256$ (стоимость задачи от N не зависит)	$H = 1.84$, $p = 0.61$
H4. Эмерджентность	RSI $\to 0$ при свободном выборе роли (1 272 роли у 16 агентов, Gini $= 0.055$), участие 87–95%, глубина иерархии ≤ 2, $\Delta \approx 1.93$	RI $= 0.94$–0.98 после шоков
H5. Воспроизводимость	Порядок протоколов повторён на трёх моделях; DeepSeek v3.2 даёт 95% качества Claude при стоимости в 24 раза ниже	$p < 0.001$ для каждой модели

Позиционирование и ограничения. Последовательная передача результатов между агентами известна (Chain-of-Agents), децентрализованная маршрутизация реализована в AgentNet; отличие метода — в моменте хода: агент сам выбирает роль по фактическому состоянию задачи и вправе отказаться, а состав команды складывается заново для каждой задачи без обучения, reward-модели и накопленной истории взаимодействий. Ограничения: оценка качества методом LLM-as-a-judge без независимой экспертной проверки; протоколы сравнивались как целостные конфигурации, вклад отдельных признаков не разделён; контроль с одной моделью при равном бюджете токенов не проводился; задачи для протоколов сэмплировались из общего банка независимо (по 30–60 на протокол), доверительные интервалы для разностей не приводятся; в сценариях с возмущениями к качеству внутри окна возмущения применялся заданный штраф; синтетические задачи; латентность Sequential $O(N)$; ключевые выводы сохраняют значимость при поправке Бонферрони ($\alpha = 0.05/20 = 0.0025$).

В **заключении** приведены основные результаты работы:

1. На основе анализа современных подходов к координации многоагентных LLM-систем показано, что доминирующая парадигма фиксированных ролей и централизованного управления переносит на ИИ-

агентов организационные ограничения человека (закреплённая специализация, стоимость переключения, издержки простоя), которыми LLM-агент не обладает. Введена шкала эндогенности $E \in [0,1]$, классифицирующая протоколы координации по тому, какие организационные решения — выбор роли, очерёдность, участие, видимость действий коллег — принимают сами агенты, а какие задаются извне.

2. Автономная ИИ-организация формализована как стохастическая динамическая система с дискретным временем $x_{t+1} = F(x_t, u_t, \tau_t, w_t, \varepsilon_t)$ с накопленным многокритериальным критерием по качеству, соответствию миссии, времени, стоимости и риску. Предложен спектр протоколов координации (Coordinator, Sequential, Broadcast, Shared и четыре биоинспирированных), различающихся типом информации, доступной агенту, сформулировано информационное условие самоорганизации $\{\text{миссия}, \tau_t, \{y_j\}_{j \prec i}\} \subseteq \mathcal{I}_i$, доказана теорема о вложении протоколов (оптимальная команда в Sequential не уступает Coordinator, Broadcast и Shared при не большем числе вызовов, а разрыв равен ценности информации, возникающей при исполнении) и разработана методика оценки с интегральными индексами баланса и устойчивости. Модель, протоколы и методика реализованы в программных комплексах «MAS-as-a-Service» и «CSB-ITBIZ», на которых выполнен вычислительный эксперимент: более 25 000 прогонов, 20 810 конфигураций, 9 моделей, пулы от 4 до 256 агентов, 8 протоколов, 4 уровня сложности задач.
3. Обнаружен и статистически подтверждён **эффект эндогенности**: на исследованном спектре протоколов зависимость качества от степени автономии немонотонна. Протокол Sequential (экзогенный порядок, эндогенный выбор роли и участия) превосходит полностью автономный Shared на 44% (Cohen's $d = 1.86$, $p < 0.0001$) и централизованный Coordinator — на 14% ($p < 0.001$); эффект воспроизведён на трёх моделях. Подтверждено **информационное условие самоорганизации**: для согласованного действия без координатора агенту выше порога способностей нужны общая цель и фактические результаты предшественников в текущей задаче; типы информации упорядочены по качеству координации как факт $>$ план $>$ намерения $\approx$ история.

4. Установлены **условия автономности**: эффективная самоорганизация требует одновременно сильной модели и подходящего протокола, причём вклады факторов не складываются (смена протокола даёт до 44% разницы в качестве, смена модели — около 14%, знак эффекта автономии зависит от модели). Введён и локализован порог способностей модели, ниже которого наблюдается эффект реверсии — жёсткая структура превосходит автономию (от $+3.5\%$ до $+10.6\%$ у Claude Sonnet 4.6 против -9.6% у GLM-5). Порог определяется саморефлексией (самоотвод 8.6% против 0.8%), многошаговым рассуждением и следованием инструкциям.
5. Зафиксирован комплекс эмерджентных свойств самоорганизующихся LLM-систем: динамическое изобретение ролей (RSI $\to 0$; 1 272 различных роли у 16 агентов Claude Sonnet 4.6 при равномерной нагрузке, Gini $= 0.055$), избирательный добровольный самоотвод (участие 87–95% агентов при $N = 16$), плоские иерархии глубиной не более 2 уровней, отсутствие обнаружимого снижения качества при росте пула до 256 агентов ($p = 0.61$) и рост стоимости всего на 11.8% при восьмикратном росте группы с фиксированными ролями, стабильность спектрального зазора матрицы зависимостей ($\Delta \approx 1.93$ при $N = 4$–64), восстановление качества после удаления агентов и подмены модели (RI $= 0.94$–0.98).
6. Показана воспроизводимость самоорганизации на закрытых и открытых моделях: DeepSeek v3.2 достигает 95% качества Claude Sonnet 4.6 на задачах L3 при стоимости API в 24 раза ниже, а на состязательных задачах L4 не уступает ей; способность к самоорганизации образует ряд Claude $>$ DeepSeek $\approx$ GLM-5 $\gg$ GigaChat 2 Max (77.5% от уровня Claude), что обосновывает мультимодельную стратегию.
7. Разработана конституционная (трёхкольцевая) модель управления автономной ИИ-организацией: неизменяемое ядро (миссия, ценности, право на самоотвод), стандарты (метрики, аудит) и адаптивные протоколы (параметры координации, инструменты), по принципу «чем ближе к стратегическому «зачем» — тем больше человеческого контроля; чем ближе к операционному «как» — тем больше автоно-

мии системы»; модель применена к автономизации бизнес-процессов (ABPS) с явным правилом эскалации к человеку.

Общее заключение. Главный вывод работы: коллективу автономных LLM-агентов выше порога способностей агент-координатор не нужен. При общей цели, фактическом контексте и минимальном каркасе очерёдности роли, участие и структура возникают сами, а качество на исследованных задачах оказывается выше, чем под управлением и чем при полной свободе без общего контекста. Результаты образуют задел для автономизации крупных систем и для *агентной экономики* — согласования действий агентов и организаций без управляющего центра.

Рекомендации. При построении автономной многоагентной системы следует: (i) задавать миссию и фактический контекст задачи вместо назначения ролей и написания инструкций; (ii) использовать протокол Sequential или его пакетный вариант как координационный каркас; (iii) перед предоставлением автономии проверять, что модель выше порога способностей на целевом классе задач, и инвестировать в качество модели, а не в численность агентов; (iv) применять мультимодельные конфигурации с открытыми моделями там, где допустима потеря 5% качества при кратной экономии; (v) закреплять границы автономии трёхкольцевой конституцией с обязательным правом агента на самоотвод и эскалацией к человеку по правилу риска и комплаенса.

Перспективы дальнейшей разработки темы. Перспективными направлениями являются: (i) валидация на реальных бизнес-процессах с экспертной оценкой качества; (ii) пакетный вариант Sequential, снижающий латентность с $O(N)$ до $O(N/K)$; (iii) развитие биоинспирированных протоколов, в которых общий контекст передаётся через следы в разделяемой среде; (iv) проверка трёхкольцевой конституции как действующего механизма управления; (v) объединение вертикального (самосовершенствование агента) и горизонтального (самоорганизация группы) интеллекта; (vi) распространение подхода на взаимодействие независимых автономных систем («агент–агент»), где общая цель формируется переговорами, а не задаётся извне [16; 17].

Публикации автора по теме диссертации

1. *Дочкина В. С.* Эмерджентная самоорганизация и устойчивость к внешним шокам автономных многоагентных систем на основе больших языковых моделей // Труды МФТИ. — 2026. — Т. 18, № 3. — С. 87—93.
2. *Дочкина В. С.* Архитектурные паттерны и самоорганизация мультиагентных систем на основе фундаментальных моделей: эффект эндогенности // Искусственный интеллект и принятие решений. — 2026. — № 3. — С. 91—106. — DOI: 10.14357/20718594260307. EDN QCEABB.
3. *Menschikov M., Evseev D., Dochkina V., Kostoev R., Perepechkin I., Anokhin P., Semenov N., Burnaev E.* PersonalAI: A Systematic Comparison of Knowledge Graph Storage and Retrieval Approaches for Personalized LLM Agents // IEEE Access. — 2026. — Vol. 14. — P. 58262–58281. — DOI: 10.1109/ACCESS.2026.3682941 (Scopus, Q1).
4. *Дочкина В. С.* Эмерджентная самоорганизация и устойчивость автономных многоагентных LLM-систем к внешним шокам // Тезисы докладов 68-й Всероссийской научной конференции МФТИ в честь 130-летия со дня рождения Н. Н. Семёнова. Прикладная математика и информатика. — 2026. — С. 41—43.
5. *Дочкина В. С.* Вычислительный эксперимент по исследованию спектральных характеристик координации в многоагентных системах на базе больших языковых моделей // Тезисы докладов 68-й Всероссийской научной конференции МФТИ в честь 130-летия со дня рождения Н. Н. Семёнова. Прикладная математика и информатика. — 2026. — С. 208—210.
6. *Дочкина В. С.* Координационные издержки и самоорганизация в многоагентных системах на базе больших языковых моделей: импликации для управления организациями // Тезисы докладов 68-й Всероссийской научной конференции МФТИ в честь 130-летия со дня рождения Н. Н. Семёнова. Аэрокосмические технологии. — 2026. — С. 214—215.
7. Программный комплекс «MAS-as-a-Service» для моделирования автономных AI-организаций : свидетельство о государственной регистрации программы для ЭВМ № 2026685681 Российская Федерация / В. С. Дочкина ; правообладатель В. С. Дочкина. — № 2026684995 ; заявл. 16.06.2026 ; зарег. 24.08.2026.
8. Автономная ИИ-система «Ника» : свидетельство о государственной регистрации программы для ЭВМ № 2026687329 Российская Федерация / В. С. Дочкина ; правообладатель В. С. Дочкина. — № 2026685314 ; заявл. 16.06.2026 ; зарег. 08.09.2026.
9. CSB-ITBIZ: программа генерации и автоматического оценивания бенчмарка ИТ- и бизнес-задач для тестирования больших языковых моделей (со встроенным банком задач L1–L4) : свидетельство о государственной регистрации программы для ЭВМ № 2026687342 Российская Федерация / В. С. Дочкина ; правообладатель В. С. Дочкина. — № 2026685232 ; заявл. 19.06.2026 ; зарег. 08.09.2026.
10. *Menschikov M., Iskornev M., Kharitonov A., Bogdanova A., Belkin M., Lisitsyna E., Sosedka A., Dochkina V., Kostoev R., Perepechkin I., Burnaev E.* PersonalAI 2.0: Enhancing Knowledge

Graph Traversal/Retrieval with Planning Mechanism for Personalized LLM Agents // IEEE Access. — 2026. — принята в печать; препринт: arXiv:2605.13481.

11. *Dochkina V.* Drop the Hierarchy and Roles: How Self-Organizing LLM Agents Outperform Designed Structures // IEEE Access. — 2026. — подана в печать; препринт: arXiv:2603.28990.

Список литературы

1. Agent Design Pattern Catalogue: A Collection of Architectural Patterns for Foundation Model based Agents / Y. Liu [et al.] // arXiv:2405.10467. — 2024.
2. MetaGPT: Meta Programming for a Multi-Agent Collaborative Framework / S. Hong [et al.] // Proc. ICLR. — 2024.
3. ChatDev: Communicative Agents for Software Development / C. Qian [et al.] // Proc. ACL. — 2024. — P. 15174–15186.
4. *Bonabeau E., Dorigo M., Theraulaz G.* Swarm Intelligence: From Natural to Artificial Systems. — Oxford Univ. Press, 1999.
5. *Kauffman S. A.* The Origins of Order: Self-Organization and Selection in Evolution. — Oxford Univ. Press, 1993.
6. Generative Agents: Interactive Simulacra of Human Behavior / J. S. Park [et al.] // Proc. UIST. — 2023. — arXiv:2304.03442.
7. CAMEL: Communicative Agents for “Mind” Exploration of Large Language Model Society / G. Li [et al.] // Proc. NeurIPS. — 2023. — arXiv:2303.17760.
8. Multiagent Cooperation and Competition with Deep Reinforcement Learning / A. Tampuu [et al.] // PLoS ONE. — 2017. — Vol. 12, no. 4. — e0172395. — DOI: 10.1371/journal.pone.0172395.
9. *Dorri A., Kanhere S. S., Jurdak R.* Multi-agent systems: A survey // IEEE Access. — 2018. — Vol. 6. — P. 28573–28593.
10. *Olfati-Saber R., Fax J. A., Murray R. M.* Consensus and cooperation in networked multi-agent systems // Proceedings of the IEEE. — 2007. — Vol. 95, no. 1. — P. 215–233.
11. *Stone P., Veloso M.* Multiagent systems: A survey from a machine learning perspective // Autonomous Robots. — 2000. — Vol. 8, no. 3. — P. 345–383.
12. *Shoham Y., Leyton-Brown K.* Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations. — Cambridge Univ. Press, 2009.
13. *Wooldridge M.* An Introduction to MultiAgent Systems. — 2nd ed. — Wiley, 2009.
14. Reflexion: Language Agents with Verbal Reinforcement Learning / N. Shinn [et al.] // Proc. NeurIPS. — 2023. — arXiv:2303.11366.
15. Voyager: An Open-Ended Embodied Agent with Large Language Models / G. Wang [et al.] // arXiv:2305.16291. — 2023.
16. Hyperagents / J. Zhang [et al.] // arXiv:2603.19461. — 2026.

17. EvoAgent: Towards Automatic Multi-Agent Generation via Evolutionary Algorithms / S. Yuan [et al.] // arXiv:2406.14228. — 2024.
18. Evolving Excellence: Automated Optimization of LLM-based Agents / P. Brookes [et al.] // arXiv:2512.09108. — 2025.
19. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation / Q. Wu [et al.] // arXiv:2308.08155. — 2023.
20. AgentVerse: Facilitating Multi-Agent Collaboration and Exploring Emergent Behaviors / W. Chen [et al.] // Proc. ICLR. — 2024.
21. GPTSwarm: Language Agents as Optimizable Graphs / M. Zhuge [et al.] // Proc. ICML. — 2024.
22. AgentNet: Decentralized Evolutionary Coordination for LLM-based Multi-Agent Systems / Y. Yang [et al.] // arXiv:2504.00587. — 2025.
23. ReSo: A Reward-driven Self-organizing LLM-based Multi-Agent System for Reasoning Tasks / H. Zhou [et al.] // Proceedings of EMNLP. — 2025.
24. MAS-ZERO: Designing Multi-Agent Systems with Zero Supervision / Z. Ke [et al.] // arXiv:2505.14996. — 2025.
25. HiVA: Self-organized Hierarchical Variable Agent via Goal-driven Semantic-Topological Evolution / J. Tang [et al.] // arXiv:2509.00189. — 2025.